PRÁCTICA 5 · ALMACENES Y MINERÍA DE DATOS

Consumo eléctrico doméstico

Preparación de una serie de tiempo para entrenar modelos de regresión y clustering.

Vega Navas Saúl · Cimmino Yáñez Nicholas Joseph
Benítez Pérez Kristian Leonel · Herrera Cuamatla Jennifer Jade

2,075,259
registros

1 min
entre cada medición

4 años
de diciembre de 2006 a noviembre de 2010

7
variables numéricas de una casa en Sceaux, Francia

Fuente: Hebrail y Berard (2006), UCI Machine Learning Repository

Del archivo de texto a una serie de tiempo

01

Encabezados

Nombres de columna en minúsculas y sin espacios sobrantes.

02

Nulos reales

El símbolo «?» del archivo se lee como nulo, no como texto.

03

Tipos de dato

Date y Time se unen en una columna datetime; las mediciones pasan a Float64.

04

Deduplicación

El medidor da una lectura por minuto, así que la clave es la marca de tiempo. Encontramos 0 duplicados.

El dataset no tiene campos de texto categóricos, así que la normalización cualitativa se limita a los encabezados.

Los faltantes llegan en bloques

1.25 %

de los registros (25,979) no tienen ninguna medición.

95 %

de esos faltantes están en solo 6 cortes de más de un día.

Cortes de más de un día

Inicio del corte	Duración
28 abr 2007	2.6 días
13 jun 2009	2.3 días
12 ene 2010	2.2 días
20 mar 2010	1.4 días
17 ago 2010	5.0 días
25 sep 2010	3.6 días

Rellenamos con interpolación lineal entre la lectura anterior y la siguiente; en los extremos, con el valor más cercano. En los cortes largos esto deja una línea recta: lo tomamos como limitación.

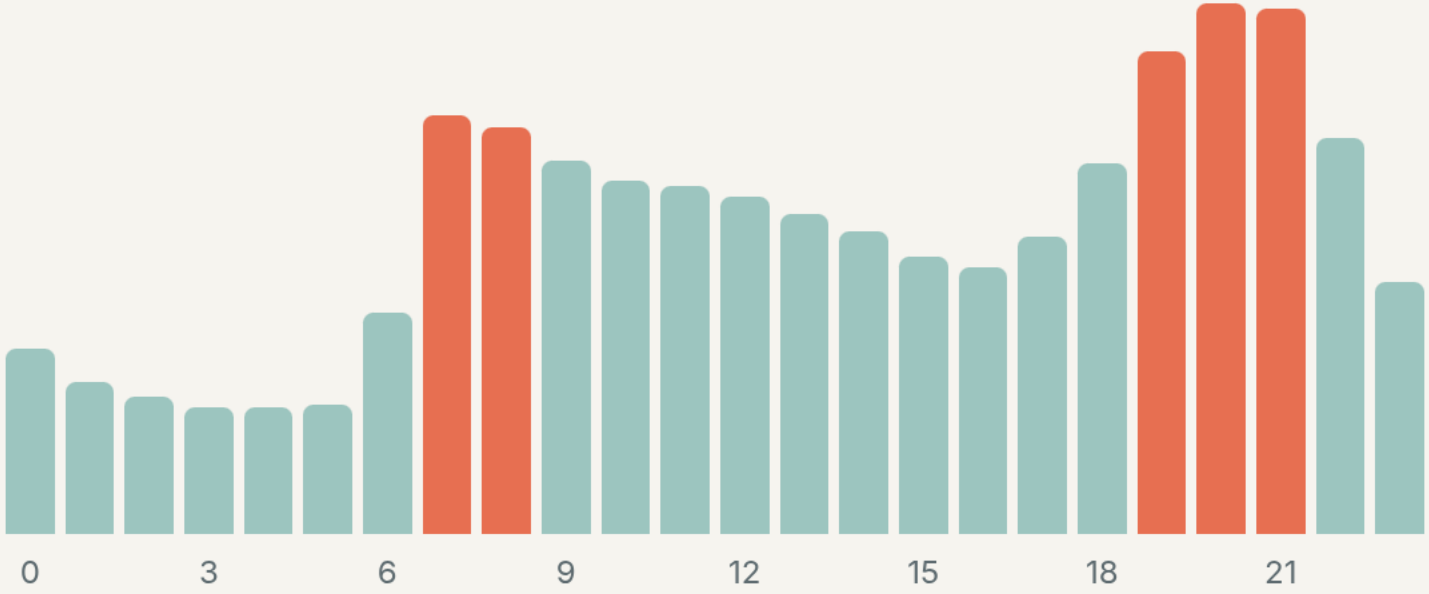
Dos picos al día: 7 h y 20 h

1.89 kW

promedio a las 20:00 h, cuatro veces la madrugada (0.45 kW).

+18 %

consumo promedio en fin de semana frente a entre semana.



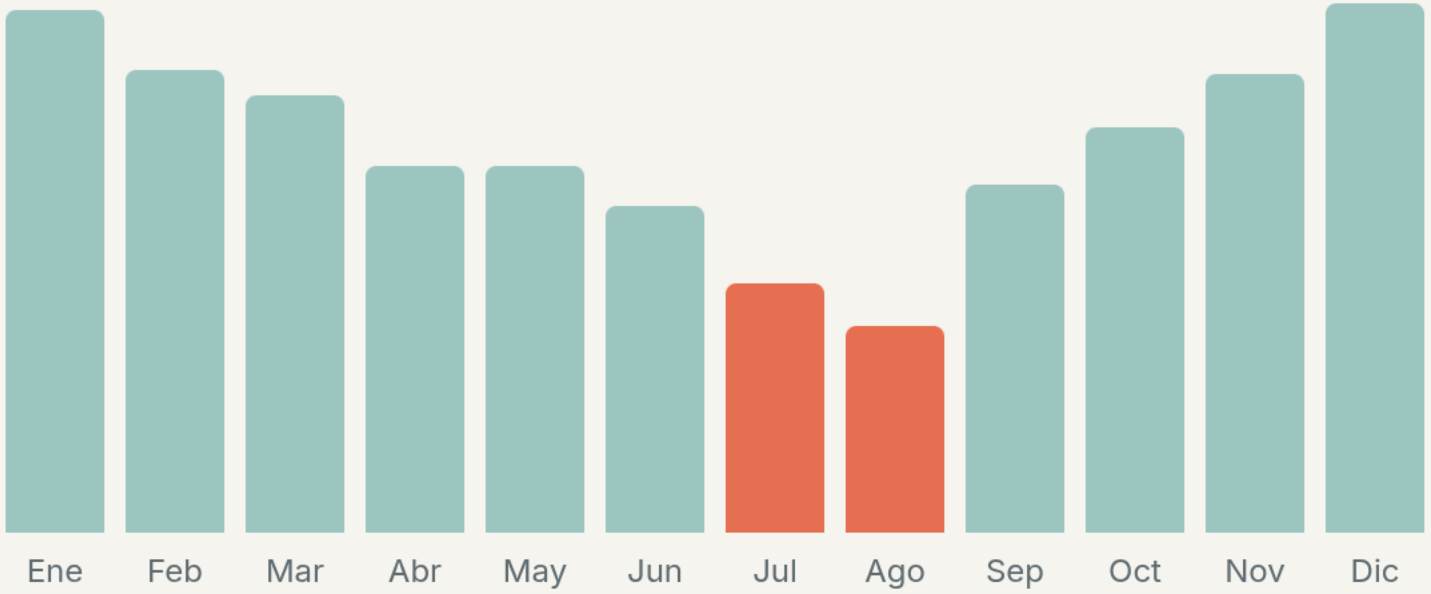
Potencia activa promedio por hora del día, 2006–2010. En coral, las horas pico (7–8 h y 19–21 h).

El verano es la temporada más tranquila

−61 %

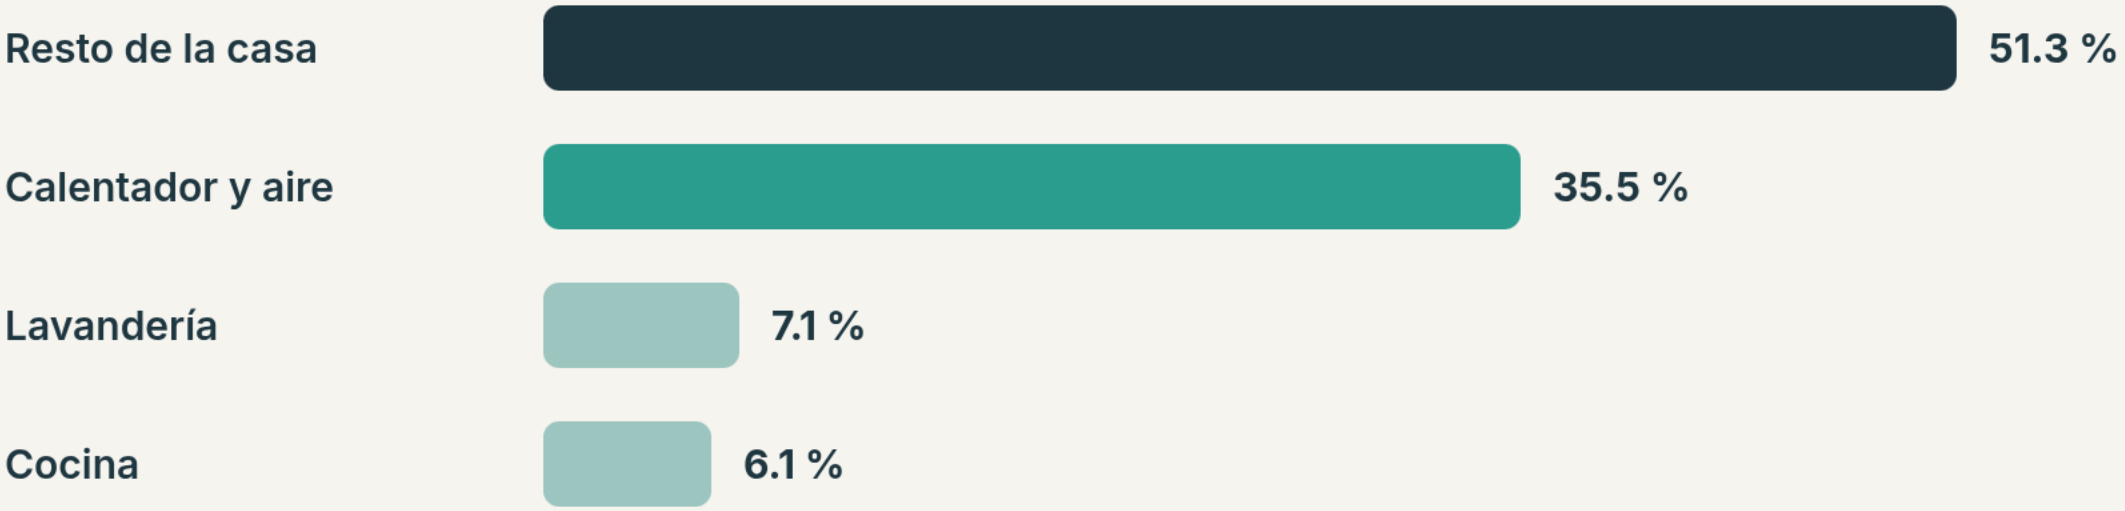
consumo promedio de agosto frente a diciembre (0.58 kW contra 1.49 kW).

El consumo baja de forma gradual desde enero y repunta en septiembre. Probablemente influyen las vacaciones y las horas de luz.



Potencia activa promedio por mes, 2006–2010. En coral, julio y agosto, los meses de menor consumo.

La mitad de la energía no tiene sub-medidor



Reparto de los 37,710 kWh medidos entre 2006 y 2010. «Resto de la casa» es la energía total menos los tres sub-medidores: iluminación, electrónicos y aparatos sin medición propia.

Z-score con parámetros del pasado

$$z = (x - \mu) / \sigma$$



Por qué z-score y no min-max

El PCA necesita variables con media 0 y varianza 1. Con min-max, picos como 11.1 kW (la media es 1.09 kW) aplastarían casi todos los valores cerca de 0.

Sin fuga de información

μ y σ salen solo del primer 80 % en orden temporal. El resto se escala con esos mismos valores, como pasaría con datos nuevos.

Una variable sobraba: la intensidad

0.9989

correlación entre potencia activa e intensidad.

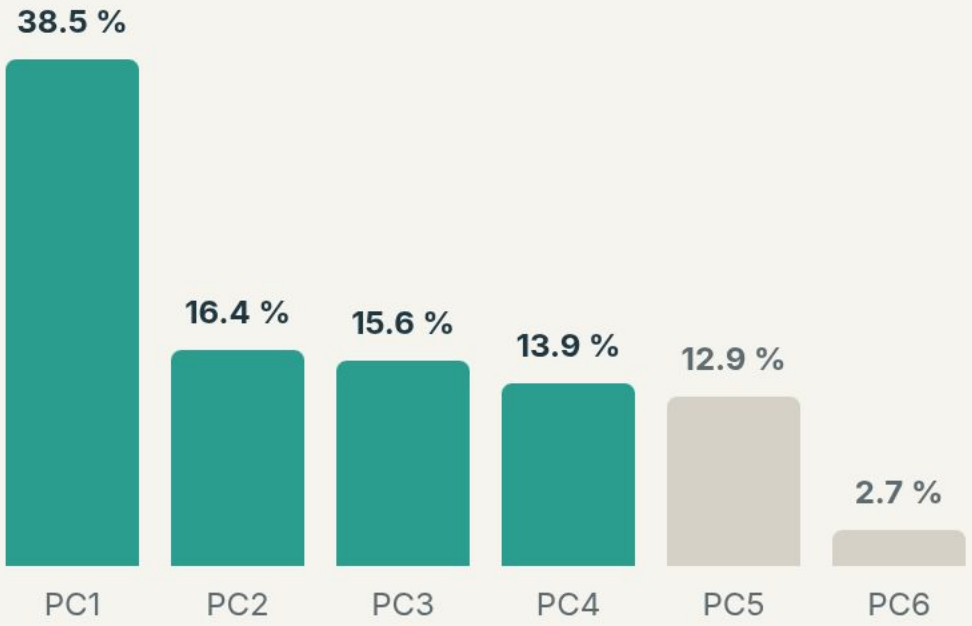
La potencia es casi voltaje × intensidad, y el voltaje apenas cambia (240 V ± 3 V). Conservamos la potencia activa porque es el consumo del hogar.

Pares con mayor correlación

Par de variables	r	Decisión
Potencia activa · Intensidad	1.00	Se descarta
Potencia activa · Calentador	0.64	Se conservan
Potencia activa · Cocina	0.48	Se conservan
Potencia activa · Lavandería	0.43	Se conservan
Potencia activa · Voltaje	−0.40	Se conservan

Umbral: $|r| \geq 0.85$. Ningún otro par lo supera; el siguiente más alto es 0.64.

4 componentes, 84 % de la varianza



Varianza explicada por componente. Retenemos las primeras cuatro (en verde) para acumular al menos 80 %.

PC1 · 38.5 %

Consumo general; el voltaje va en contra

PC2 · 16.4 %

Lavandería y reactiva vs. calentador

PC3 · 15.6 %

Cocina vs. lavandería

PC4 · 13.9 %

Reactiva y calentador vs. cocina y lavandería

PC5 y PC6 se descartan: juntas aportan el 15.6 %.

Datos listos para modelar

0

nulos y duplicados en el dataset final, escalado sin ver el futuro.

84.4 %

de la varianza en 4 componentes, a partir de 6 variables tras Pearson.

20:00 h

es la hora pico; el consumo también cambia por día de la semana y estación.

51 %

de la energía no tiene sub-medidor: una línea por investigar.

Resultado: prepared_consumption.csv, con 2,075,259 filas y 11 columnas, listo para regresión y clustering.